

מבוא לבינה מלאכותית

סמסטר חורף תשפ"ז

מטלה 5 RL and MDP – 5

תאריך הגשה: 23:55 24.01.2026



הנחיות

- שאלות בנושא מטלה זו יש לשאול דרך המודל, בפורום "מטלה 4".
- הוראות להגשת המטלה מופיעים בסוף מסמך זה.
- הקבצים הנדרשים להרצת הקוד הינם:
 - q_learning.py
 - common.py
 - value_iteration.py
 - plotting.py
 - cliff_walking_experiment.py
 - gamblers_experiment.py
 - requirements.txt
- העבודה להגשת בזוגות בלבד אלא אם כן המגנים קיבלו אישור להגשת שאינה בזוגות.
- פתרון המטלה שתגלו "יבדק מול שאר ההצעות על ידי תוכנת העתקות".
- **מי שימצא כי העתיק יכשל בקורס וכן יועבר לועדת משמעת אוניברסיטאית.**
- הפרויקט נכתב ויבדק בשפת התכנות Python, גרסה 3.10.
- **יש להתקן את החבילות על פי הקובץ requirements.txt.**
 - על מנת לוודא שהביבה מותקנת במלואה יש להריץ:
pip install "gymnasium[toy-text]"
- מסמך זה בניו באופן הבא: תיאור המטלה, תיאור הבעיה, שאלות המטלה והסביר על המימוש הקיים והסביר על הגשת המטלה.

תיאור המטלה:

בתרגיל זה אתם מתבקשים למש את האלגוריתמים Q Learning ו-Q Iteration על מנת לפתור שתי בעיות.

בחלק הראשון של התרגיל עליכם למש את האלגוריתם של Q Learning כדי לפתור את בעיית cliff walking ולאחר מכן עליכם למש את האלגוריתם Value Iteration על מנת שתוכלו לפתור את בעיית המהמר (עם שיבוי).

בעיית ה-Cliff Walking

מצרף לינק הסבר על הסביבה - https://gymnasium.farama.org/environments/toy_text/cliff_walking בבעיה זו הממצבים והפעולות מוגבלים על ידי מספרים המציגים את המצב (על פי המימדים של המפה) ובוינו התנועה של הסוכן (0 עד 3 שבור היכונים בהם הסוכן מסוגל לנוע).

עליכם למש את הפונקציות הבאות במחלקה :QLearning

```
def update(self, state: int, action: int, reward: float,  
new_state: int):
```

הfonkzia מקבלת את המצב הנוכחי, ה-reward והמצב הבא ומעדכנת את ערך ה-table Q בהתאם על פיו משווהות בלמן שנלמדה בכיתה.

```
def select_epsilon_greedy_action(self, state: int) -> int:
```

הfonkzia מקבלת את המצב הנוכחי ומוחזירה את הפעולה לביצוע על פי אלגוריתם epsilon greedy. שימושו לב, אם ישן מספר פעולות אופטימליות מומלץ לבצע breaking tie ונדומלי.

```
def train_episode(self, env: gym.Env) -> Tuple[float, int]:
```

הfonkzia מקבלת instance של הסביבה ומאמנת את הסוכן על ה-episode. הfonkzia מחזירה את ה-reward שהתקבל ב-episode **הfonkzia צירבה לrox עד אשר מגע למצב טרמינלי**. שימושו לב, פועלתו זו *לא* מקבלת מספר צעדים וריצה עד אשר הסוכן נפל או עד אשר המשימה הצלחה והתקבל reward.

שימושו לב, הfonkzia (env.step(action) מבצעת צעד אחד בלבד על הסביבה. ערכי החזרה של פונקציה זו הם:

```
new_state, reward, terminated, truncated, info =  
env.step(action)
```

כאשר המשתנה truncated מצין האם האינטראקציה עם הסביבה הסתיימה בצורה פתאומית (כישלון המשימה או כישלון בסביבה וכו') והערך terminated אומר האם המשחק הסתיים (בהצלחה). על מנת לדעת האם ה-episode הסתיים, בדקו האם מתקיים כי terminated או truncated מקבלים ערך True.

```
def run_environment(self, env: gym.Env, num_episodes: int) ->  
Tuple[List[float], List[int]]:
```

הfonkzia מרים על הסביבה את מספר ה-episodes שנותן בפרמטר. על הfonkzia להחזיר את ה-rewards עבור כל ה-episodes כמו גם את מספר הצעדים שבוצעו בכל episode.

בעית ה-Gambler

בשאלה זו עליכם למש את אלגוריתם value iteration על גירסה חדשה של בעית המהמר.



בעית המהמר המקורי מוגדרת באופן הבא:

מהמר מקבל החלטנות להמר על התוצאות של רצף הטלות מטבע. אם המטבע נוחת על צד ה"עץ", הוא זוכה במספר דולרים כמספר הסכום שהימר; אם נוחת על צד "פל'", הוא מפסיד את הסכום שהימר. המשחק מסתיים כאשר המהמר מנצח ומגיע למטרה של 100 דולר, או מפסיד כאשר נגמר לו הכספי.

בכל הטלה, המהמר חייב להחליט איזה חלק מההון שלו להמר, במספרים שלמים של דולרים. בעיה זו יכולה להיות מנוסחת כ MDP-סופי, אפיוזדי ולא מוזל.

המצב הוא ב모ת הבספ' הנוכחית של המהמר. $s \in \{1, 2, \dots, 99\}$,

הפעולות הן סכומי ההימור. $a \in \{0, 1, \dots, \min(s, 100) - s\}$, התגמול הוא אפס בכל המעברים פרט לאלה שבהם המהמר מגיע למטרה שלו, אז הוא $1 + a$.

עבור הבעיה שלנו אנחנו נניח כי במקומות מטבע עם שני צדדים, למהמר יש 2 קוביות הוגנות כאשר התוצאות של הטליה הן כדלהלן:

1. כאשר יוצא סכום הקטן מ 7 – המהמר מפסיד את ההימור שהוא שם. תזכורת: הסיכוי לכך הוא $5/12$.
2. כאשר יוצא סכום השווה ל 7 – המהמר מרוויח את הסכום שהימר עלי. תזכורת: הסיכוי לכך הוא $1/6$.
3. כאשר יוצא סכום הגדל מ 7 – המהמר מפסיד מחצית מהhimor שהוא שם (מעוגל כלפי מעלה).

תזכורת: הסיכוי לכך הוא $5/12$.

עליכם למש את הפעולות הבאות במחלקה ValueIteration:

```
def calculate_q_values(self, current_capital: int,
value_function: np.ndarray, rewards: np.ndarray) ->
np.ndarray:
```

הfonקציה מחשבת את ה- `value` בהינתן המצב הנוכחי, ווסף ה-`rewards` (מוגדרים להיות אפס לכל אחד מהמצבים פרט למצב האחרון שהוא reward של 100).

שימוש לב – עליים להשתמש בהסתברויות הנ"ל על מנת לחשב את הערכי ה-[a,d]-[Q] כאשר ה- s הינו המצב הנוכחי (current_capital) הנitin בקלט לפונקציה.

עליכם למש גם את הפונקציה

```
def value_iteration_for_gamblers(self) -> Tuple[np.ndarray, np.ndarray]:
```

אשר מרים את תחילת ה- value iteration עד להתכנסות.

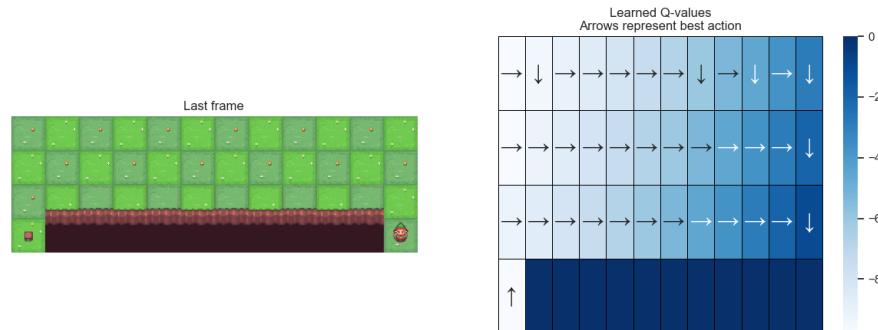
שימוש לב, על הפעולה להחזיר את ה-values כמו גם את ה-policy האופטימלי שוחשב. מצופה להחזיר באופן הבא:

return policy, V

שימוש לב, ישנו 101 ערכים אפשריים ל-rewards – 0 – 100 * כולם* .

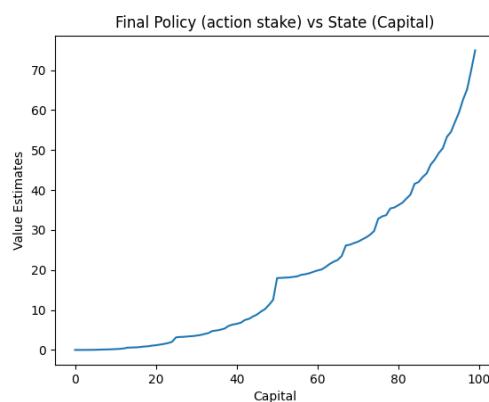
בדיקות נכונות:

בקבצים cliff_walking_experiment.py ו gamblers_experiment.py מצוים תרחישים אשר ידקו את נכונות האלגוריתם שאתם כתובים.



עבור הרצת הסוכן על בעיית cliff walking מצופה מכם לקבל תוצאה כזו לאחר סיום הריצה.

עבור בעיית המהמר עם הפרמטרים שבקובץ מצופה מכם לקבל גרפ' דילול:



הגשת המטלה:

המטלה תיבדק ב-PL7, הקבצים שעלייכם להגיש הם `qy.py`, `value_iteration.py` ו-`q_learning.py`. הקוד שלכם יעבור בדיקות אוטומטיות על תרחישים בדיקה שمدמים את התרחישים שאתם מרכיבים פה.

הסבירה מרכיבת את הקוד שלכם על מספר תרחישים וכן הרצפה אמרורה ל渴cht מספר שניות.

 **בהצלחה**